

Министерство образования и науки Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
—
Институт компьютерных наук и технологий
Кафедра «Информационная безопасность компьютерных систем»

ЛАБОРАТОРНАЯ РАБОТА № 2

по дисциплине «Теория вероятностей и математическая статистика»

Выполнила
студентк гр. 23508/4

<подпись>

Проценко М.А.

Проверила ассистент

<подпись>

Лаврова Д.С.

Санкт-Петербург
2016

Формулировка задания 1

1. Используя таблицу значений функции $f(x)$, записать 100 цифр, выбирая из каждого значения функции второй знак справа (указать точность округления). С помощью критерия хи-квадрат проверить для такой выборки гипотезу о случайности цифр 0, 1, ..., 9. Уровень значимости положить равным: а) 0,05; б) 0,01. Функцию $f(x)$ брать в соответствии с вариантом.

Решение:

1. Была взята функция $\ln x$ в соответствии с вариантом.
2. Гипотеза H_0 : вторая цифра справа случайна.

$$P_{(s=k)} = \frac{a^k}{k!} e^{-a}$$

3. Закон редких событий – распределение Пуассона:
4. Рассчитали количество встречаемости каждой цифры (0, 1, ..., 9)
5. Вычислили параметр a , который должен получиться равен среднему значению.

$$P_{(s=k)} = \frac{a^k}{k!} e^{-a}$$

6. Вычислим P_i по формуле:
7. Затем вычислили $n \cdot P_i$
8. Далее посчитали $(N_i - N \cdot p_i)^2$
9. Получившиеся значения разделим на $N \cdot p_i$ и сложим. Это и будет критерий хи-квадрат. У нас он получился равным 92.5 (наблюдаемое значение). Это больше чем 15.5 (хи-квадрат критическое при $\alpha=0.01$) и больше чем 20.1 (хи-квадрат наблюдаемое при $\alpha=0.05$)
10. Таким образом наша гипотеза не подтвердилась, отсюда делаем вывод, что вторая цифра в числе не случайна.

Формулировка задания 2

Взять три текста из разных областей знаний, объемом 2000 знаков (включая пробелы) каждый. На основе анализа частот встречаемости букв проверить гипотезу об однородности этих текстов.

Решение:

Были взяты три текста из разных областей знаний (текст из курса философии, статья про теннис из википедии, технический текст).

Для оценки однородности текстов был использован критерий Колмогорова-Смирнова.

Однако этим критерием можно сравнить только 2 выборки. Поэтому, так как у нас 3 текста, а следовательно и три выборки, нам придется применить этот критерий 3 раза (т.к. три пары выборок).

Вычисления:

1. Вычисляем относительные частоты f , равные частному от деления частот на объем выборки, для двух имеющихся выборок.
2. Далее определяем модуль разности соответствующих относительных частот для контрольной и экспериментальной выборок.

3. Среди полученных модулей разностей относительных частот выбираем наибольший модуль, который обозначается d_{\max} .
4. Эмпирическое значение критерия $\lambda_{\text{эмп}}$ определяется с помощью формулы:

$$\lambda_{\text{эмп}} = d_{\max} \cdot \sqrt{\frac{n_1 \cdot n_2}{n_1 + n_2}}$$

5. Чтобы сделать вывод о схожести по рассматриваемому критерию между двумя текстами, сравним экспериментальное значение критерия с его критическим значением, определяемым по специальной таблице, исходя из уровня значимости. В качестве нулевой гипотезы примем утверждение о том, что сравниваемые тексты незначительно отличаются друг от друга. При этом нулевую гипотезу следует принять в том случае, если наблюдаемое значение критерия не превосходит его критического значения.
6. По таблице определяем критическое значение критерия: $\lambda_{\text{кр}}(0,05)=1,36$.
7. Таким образом, $\lambda_{\text{эмп}} < 1,36 = \lambda_{\text{кр}}$ только в первом и третьем случае. Следовательно, нулевая гипотеза принимается для текстов (1,2) и (2,3), и группы по рассмотренному признаку отличаются не существенно. Текста 1 и 3 отвергают гипотезу о том что тексты однородны и принимают конкурирующую гипотезу о том, что текста неоднородны.

S	T	U
Аэмп1	Аэмп2	Аэмп3
1,309896	1,865389	1,074085

Формулировка задания № 3

Построить критерий отношения правдоподобия для проверки двух простых гипотез о неизвестном параметре распределения из расчетных заданий № 1.3 и 1.4.

3.1) Для показательного распределения (задание 1.3) сформулировать гипотезы:

- для значения $a = 0,134$;
- для значения $a = 3,13$.

3.2) Для нормального распределения (задание 1.4) сформулировать гипотезы:

- для математического ожидания ($M = 9$);
- для дисперсии ($\sigma^2 = 3,13$).

Выполнение задания № 3.1

Для выполнения задания 3.1 из результатов пункта 3 первой лабораторной работы были извлечены данные о вариационных рядах выборок:

	A	B
1	0,013311	0,030815
2	0,045817	0,060681
3	0,077253	0,089626
4	0,107653	0,11768
5	0,137051	0,144868
6	0,165481	0,17122
7	0,192974	0,196759
8	0,219562	0,221511
9	0,245274	0,2455
10	0,270138	0,26875
11	0,294184	0,291284
12	0,317437	0,313123
13	0,339924	0,334289
14	0,36167	0,354803
15	0,3827	0,374685

И т.д. Всего по 100 значений в выборках.

Были сформулированы две простые гипотезы:

- Гипотеза H_0 : элементы выборки имеют показательное распределение с параметром $a_0 = 3, 13$ (т.е. $x_i \in \exp(a_0)$, $a_0 = 3, 13$)
- Гипотеза H_1 : элементы выборки имеют показательное распределение с параметром $a_1 = 0, 134$ (т.е. $x_i \in \exp(a_1)$, $a_1 = 0, 134$)

Для проверки сформулированных гипотез, необходимо построить критерий отношения правдоподобия. Сделать это можно, вычислив функцию отношения правдоподобия Λ :

$$\Lambda = \frac{p_1(x_1) \cdot p_1(x_2) \cdot \dots \cdot p_1(x_n)}{p_0(x_1) \cdot p_0(x_2) \cdot \dots \cdot p_0(x_n)}$$

Под x_i понимается i -ый элемент выборки, под $p_j(x_i)$ - вероятность случайной величине, распределенной согласно гипотезе H_j , принять значение x_i , n - количество элементов в выборке и в нашем случае $n = 100$.

Что же отображает Λ ? Зададим некоторое число $c > 0$. Если значение Λ оказывается не больше, чем c , то принимается гипотеза H_0 , иначе - H_1 . Подставим в вычисление Λ вероятности, которые соответствуют сформулированным нами гипотезам:

$$\Lambda = \frac{a_1^n e^{-a_1 \sum x_i}}{a_0^n e^{-a_0 \sum x_i}}$$

Нам нужно выразить $\sum x_i$ - для этого, очевидно, нам нужно прологарифмировать наше равенство. Подставляя результат в дальнейшем в наше неравенство с параметром c , будем считать, что $c_1 = \ln c$. Итак, логарифмируем:

$$\ln \Lambda = n \ln \frac{a_1}{a_0} - (a_1 - a_0) \sum x_i$$

Теперь, как уже и говорилось, подставим $\ln \Lambda$ в неравенство $\ln \Lambda \leq \ln c$ и выразим $\sum x_i$:

$$\sum x_i \leq \frac{c_1 - n \ln \frac{a_1}{a_0}}{a_0 - a_1}$$

Далее нам потребуются некоторые свойства гамма-распределения. Гамма-распределение - двухпараметрическое семейство абсолютно непрерывных распределений. Оно обладает следующими интересующими нас свойствами:

- Экспоненциальное распределение - частный случай гамма-распределения: $\Gamma(1/\theta, 1) = \text{Exp}(\theta)$
- χ^2 -распределение - частный случай гамма-распределения: $\Gamma(2, \frac{n}{2}) = \chi^2(n)$

В соответствии с этим, получаем следующее:

$$\sum x_i \in \Gamma(a; n), b \sum x_i \in \Gamma(\frac{a}{b}; n)$$

$$2a \sum x_i \in \chi^2(2n)$$

Теперь выразим вероятность ошибки первого рода:

$$\alpha = P \left\{ \sum x_i > \frac{c_1 - n \ln \frac{a_1}{a_0}}{a_0 - a_1} \mid H_0 \right\}$$

$$\alpha = P \left\{ 2a_0 \sum x_i > 2a_0 \frac{c_1 - n \ln \frac{a_1}{a_0}}{a_0 - a_1} \mid H_0 \right\} = 1 - F(2a_0 \frac{c_1 - n \ln \frac{a_1}{a_0}}{a_0 - a_1}; 2n)$$

Здесь функция $F(x; 2n)$ - функция $\chi^2(2n)$ -распределения. Выходит следующее:

$$\frac{c_1 - n \ln \frac{a_1}{a_0}}{a_0 - a_1} = \frac{X(1-\alpha; 2n)}{2a_0}$$

Здесь, очевидно, $X(1-\alpha; 2n)$ - α -квантиль $\chi^2(2n)$ -распределения. Вычислим это отношение при $\alpha = 0,01$:

$$\frac{c_1 - n \ln \frac{a_1}{a_0}}{a_0 - a_1} = \frac{X(1-\alpha; 2n)}{2a_0} = \frac{249,445}{2 \cdot 2,06} \cong 60,545$$

Посчитаем суммы первой и второй выборок. Для выборки 1 сумма равна 71.101, для выборки 2 сумма равна 69.923.

Выводы по заданию № 3.1

Т.к. сумма элементов выборок меньше, чем вычисленное нами отношение (60,545), принимается гипотеза H_0 . Результаты выполнения данного задания согласуются с результатами, полученными в ходе первой лабораторной работы.

Выполнение задания № 3.2

Для выполнения задания 3.2 из результатов пункта 4 первой лабораторной работы были извлечены данные о вариационном ряде следующей выборки:

C	D
0,006	0,005
0,006	0,008
0,003	0,004
0,008	0,007
0,009	0,004
0,003	0,003
0,004	0,009
0,003	0,005
0,004	0,004
0,005	0,005
0,004	0,003
0,004	0,008
0,005	0,006
0,008	0,004
0,006	0,003
---	---

И т.д.

Были сформулированы две простые гипотезы о мат.ожидании:

- Гипотеза H0: элементы выборки имеют нормальное распределение мат. ожиданием $a_0 = 6$ и дисперсией $\sigma^2 = 4,136$
- Гипотеза H1: элементы выборки имеют нормальное распределение мат. ожиданием $a_0 = 25$ и дисперсией $\sigma^2 = 4.136$.

Для проверки сформулированных гипотез, необходимо построить критерий отношения правдоподобия. Сделать это можно, вычислив функцию отношения правдоподобия Λ :

$$\Lambda = \frac{e^{-\frac{1}{2\sigma^2} \sum (x_i - a_1)^2}}{e^{-\frac{1}{2\sigma^2} \sum (x_i - a_0)^2}}$$

Нам нужно выразить $\sum x_i$ - для этого, очевидно, нам нужно прологарифмировать наше равенство. Подставляя результат в дальнейшем в наше неравенство с параметром c , будем считать, что $c_1 = \ln c$. Итак, логарифмируем:

$$\ln \Lambda = \frac{a_1 - a_0}{\sigma^2} \left(\sum x_i - n \frac{a_1 + a_0}{2} \right)$$

Теперь, как уже и говорилось, подставим $\ln \Lambda$ в неравенство $\ln \Lambda \leq \ln c$ и выразим $\sum x_i$:

$$\sum x_i \leq \frac{c_1 \sigma^2}{a_1 - a_0} + n \frac{a_1 + a_0}{2}$$

Теперь выразим вероятность ошибки первого рода:

$$\alpha = P \left\{ \sum x_i > \frac{c_1 \sigma^2}{a_1 - a_0} + n \frac{a_1 + a_0}{2} \mid H_0 \right\}$$

$$\alpha = P \left\{ \sum x_i > \frac{c_1 \sigma^2}{a_1 - a_0} + n \frac{a_1 + a_0}{2} \mid H_0 \right\} = 1 - \Phi \left(\frac{\frac{c_1 \sigma^2}{a_1 - a_0} + n \frac{a_1 + a_0}{2} - n a_0}{\sqrt{n \sigma^2}} \right)$$

Здесь функция $\Phi(x)$ - функция стандартного нормального распределения. Выходит следующее:

$$\frac{c_1 \sigma^2}{a_1 - a_0} + n \frac{a_1 + a_0}{2} = Q(1 - \alpha) \sqrt{n \sigma^2} + n a_0$$

Здесь, очевидно, $Q(\alpha)$ - α -квантиль стандартного нормального распределения. Вычислим это отношение при $\alpha = 0,01$:

$$\frac{c_1 \sigma^2}{a_1 - a_0} + n \frac{a_1 + a_0}{2} = Q(1 - \alpha) \sqrt{n \sigma^2} + n a_0 =$$

$$= 647.304$$

Сумма представленной выборки оказалась равно 0.561.

Используя ту же выборку были сформулированы две простые гипотезы о дисперсии:

- Гипотеза H_0 : элементы выборки имеют нормальное распределение мат. ожиданием $a_0 = 6$ и дисперсией $\sigma^2 = 4.136$.
- Гипотеза H_1 : элементы выборки имеют нормальное распределение мат. ожиданием $a_0 = 6$ и дисперсией $\sigma^2 = 25$

Для проверки сформулированных гипотез, необходимо построить критерий отношения правдоподобия. Сделать это можно, вычислив функцию отношения правдоподобия Λ :

$$\Lambda = \frac{\left(\frac{1}{2\pi\sigma_1^2}\right) e^{-\frac{1}{2\sigma_1^2} \sum (x_i - a)^2}}{\left(\frac{1}{2\pi\sigma_0^2}\right) e^{-\frac{1}{2\sigma_0^2} \sum (x_i - a)^2}}$$

Нам нужно выразить $\sum x_i$ - для этого, очевидно, нам нужно прологарифмировать наше равенство. Подставляя результат в дальнейшем в наше неравенство с параметром c , будем считать, что $c_1 = \ln c$. Итак, логарифмируем:

$$\ln \Lambda = n \ln \frac{\sigma_0^2}{\sigma_1^2} - \frac{1}{2} \left(\frac{1}{\sigma_1^2} - \frac{1}{\sigma_0^2} \right) \sum (x_i - a)^2$$

Теперь, как уже и говорилось, подставим $\ln \Lambda$ в неравенство $\ln \Lambda \leq \ln c$ и выразим $\sum (x_i - a)^2$:

$$\sum (x_i - a)^2 \leq 2 \cdot \frac{c_1 - n \ln \frac{\sigma_0^2}{\sigma_1^2}}{\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2}}$$

Заметим, что $\frac{x_i - a}{\sigma} \in N(0; 1) \Rightarrow \frac{\sum (x_i - a)^2}{\sigma^2} \in \chi^2(n)$. В соответствии с этим выразим теперь вероятность ошибки первого рода:

$$\alpha = P \left\{ \sum (x_i - a)^2 > 2 \cdot \frac{c_1 - n \ln \frac{\sigma_0^2}{\sigma_1^2}}{\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2}} \mid H_0 \right\}$$

$$\alpha = P \left\{ \frac{1}{\sigma_0^2} \sum (x_i - a)^2 > \frac{2}{\sigma_0^2} \cdot \frac{c_1 - n \ln \frac{\sigma_0^2}{\sigma_1^2}}{\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2}} \middle| H_0 \right\} = 1 - F \left(\frac{2}{\sigma_0^2} \cdot \frac{c_1 - n \ln \frac{\sigma_0^2}{\sigma_1^2}}{\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2}}; n \right)$$

Здесь функция $F(x)$ - функция $\chi^2(n)$ -распределения. Выходит следующее:

$$2 \cdot \frac{c_1 - n \ln \frac{\sigma_0^2}{\sigma_1^2}}{\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2}} = \sigma_0^2 X(1 - \alpha; n)$$

Здесь, очевидно, $X(1 - \alpha; n)$ - α -квантиль $\chi^2(n)$ -распределения. Вычислим это отношение при $\alpha = 0,01$:

$$2 \cdot \frac{c_1 - n \ln \frac{\sigma_0^2}{\sigma_1^2}}{\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2}} = \sigma_0^2 X(1 - \alpha; n) = 3,06 \cdot 135,807 \cong 415,569$$

Сумма квадратов $(x_i - a)$ равна 0.03.

Выводы по заданию № 3.2

Для выборки 1, имеем следующее: в случае с проверкой гипотез для мат. ожидания, сумма элементов выборки: $\sum x_i = 0.561$, а вычисленное ранее отношение, включающее квантиль стандартного нормального распределения: $Q(1 - \alpha) \sqrt{n\sigma^2} + na_0 = 2,326 \cdot \sqrt{100 \cdot 3,06} + 100 \cdot 9 \cong 940,688$. Следовательно, принимаем гипотезу о мат. ожидании H_0 при $\alpha = 0,01$. В случае проверки гипотез для дисперсии, $P(x_i - a) = 0.03$, в то время как отношение, содержащее α -квантиль $\chi^2(n)$ -распределения: $\sigma^2 X(1 - \alpha; n) = 3,06 \cdot 135,807 \cong 415,569$. Следовательно, принимаем гипотезу о дисперсии H_0 с заданным уровнем ошибки первого рода.